

基于 Grounding DINO 的开放词汇目标检测复现与评估

Student Name: 李泽均, 崔子璇, 唐明强, 李程

Student ID: 12311010, 12311007, 12312417, 12111913

1 Introduction

开放词汇目标检测 (Open-Vocabulary Object Detection, OVOD) 旨在使检测模型能够根据任意文本描述定位图像中的目标, 而不是只能识别训练集中预定义的固定类别。例如, 传统目标检测模型通常只能检测 COCO 中的 80 个类别, 而开放词汇检测模型可以通过文本提示词 (prompt) 检测 “the person holding an umbrella”、“a laptop on the table” 等更灵活的语义目标。

本项目选择 Project 4: Open-Vocabulary Object Detection and Visual Grounding, 重点复现并评估 Grounding DINO 在开放词汇目标检测任务上的表现。与经典目标检测相比, 开放词汇检测的主要挑战包括: 模型需要同时理解图像和自然语言文本; 检测类别不再固定, prompt 的设计会直接影响预测结果; 文本标签与标准数据集类别之间存在映射问题; 小目标、遮挡目标和密集目标仍然容易漏检或误检。

本项目的目标是构建一个完整的开放词汇检测实验流程, 包括模型推理、COCO 子集构建、量化评估、阈值分析、prompt 改进以及失败案例分析。我们基于 HuggingFace Transformers 中的 Grounding DINO 实现推理流程, 并在 COCO val2017 的 20 类子集上进行定量评估。

2 Related works

开放词汇目标检测通常依赖视觉-语言模型, 将图像区域与文本描述对齐。早期的目标检测方法如 Faster R-CNN、YOLO 系列和 DETR 主要针对固定类别进行训练, 而开放词汇检测进一步要求模型能泛化到新的文本类别。

CLIP 通过大规模图文对比学习, 将图像和文本映射到共享语义空间, 为开放词汇识别提供了基础。OWL-ViT 将视觉 Transformer 与文本编码器结合, 可以直接使用文本查询进行目标检测。GLIP 将目标检测任务统一为图文 grounding 问题, 通过短语与图像区域的对齐提升开放词汇能力。Grounding DINO 进一步结合 DINO 检测器和文本 grounding 机制, 在开放词汇检测和 phrase grounding 上取得了较好的效果。

本项目选择 Grounding DINO 作为主要复现对象, 原因是其开源实现成熟, HuggingFace 提供了较稳定的模型接口, 同时它能够直接接收文本 prompt 并输出检测框、文本标签和置信度, 适合作为课程项目中的复现和评估对象。

3 Method

3.1 整体流程

本项目实现的流程如下：

1. 输入图像和文本 prompt；
2. 使用 Grounding DINO 进行开放词汇检测；
3. 输出检测框、文本标签和置信度；
4. 将预测结果可视化；
5. 将预测结果转换为 COCO detection 格式；
6. 使用 COCOeval 计算 AP、AP50、AP75 和 AR 等指标；
7. 对不同 threshold 和 prompt 策略进行对比分析；
8. 导出 false positive 和 false negative 失败案例。

3.2 Grounding DINO 模型结构

我们没有从头训练模型，而是使用预训练的 Grounding DINO 模型进行 zero-shot 推理。本文所有正式定量实验统一使用 HuggingFace 模型 `IDEA-Research/grounding-dino-base`。这样可以避免不同模型规模带来的干扰，使实验重点集中在 threshold、prompt 方式和后处理策略对开放词汇检测结果的影响。

Grounding DINO 将开放词汇目标检测建模为图像区域与文本短语之间的匹配问题。模型输入包括一张图像和一段文本 prompt，例如 `a person. a car. a dog.`。图像首先经过视觉 backbone 提取多尺度图像特征，文本 prompt 经过文本编码器得到 token-level 的语言特征。随后模型通过 cross-modality feature fusion 将视觉特征和语言特征进行交互，使图像区域能够感知文本类别信息。

与传统 DETR 类检测器不同，Grounding DINO 使用 language-guided query selection。也就是说，decoder 的 object queries 不是完全随机或固定初始化，而是优先选择与文本 prompt 更相关的图像区域作为候选 query。这样可以让模型在开放词汇场景下更快地关注可能包含目标的区域。

在 decoder 阶段，每个 query 会同时与图像特征和文本特征交互，最终输出两类结果：一类是 bounding box，用于表示目标位置；另一类是 text relevance score，用于表示该区域与 prompt 中各个文本 token 或短语的匹配程度。HuggingFace 的 `post_process_grounded_object_detection` 会进一步根据 box threshold 和 text threshold 筛选预测框，并恢复出最终的 `boxes`、`scores` 和 `text_labels`。

3.3 Prompt 设计与类别表示

基础 prompt 使用 COCO 20 类类别名，统一转为英文小写，并用句号分隔。例如：

a person. a bicycle. a car. a motorcycle. a bus. a truck. ...

在基础方法中，我们将 20 个类别放在同一个 prompt 中一次性推理。这种方式速度较快，但模型有时会输出混合标签，例如 `traffic light an umbrella`，从而影响类别映射和评估。

为改进这一问题，我们实现了 per-class prompt 策略：每次只查询一个类别，例如 `a person.`、`a car.`、`a traffic light.`，然后将每个类别的检测结果合并。该方法速度明显变慢，但可以避免多类别 prompt 造成的文本标签混乱，并提高 recall。

3.4 推理与结果解析

本项目的推理实现主要位于 `Grounding DINO wrapper` 和 `inference script` 两部分。前者封装 HuggingFace processor 与 zero-shot object detection model 的加载逻辑，后者负责命令行参数解析、图片读取、批量推理和结果保存。推理时，processor 会把 PIL 图像和文本 prompt 转换为模型输入，包括图像张量、文本 token 和 attention mask。

模型前向传播后得到的 outputs 还不是最终检测框，而是 decoder query 对应的原始 box 预测和文本匹配分数。随后代码调用 `processor.post_process_grounded_object_detection`，将模型输出转换为原图坐标系下的检测结果。最终统一返回：

- `boxes_xyxy`: 检测框，格式为 `[x0, y0, x1, y1]`；
- `scores`: 检测置信度；
- `text_labels`: 模型匹配到的文本类别；
- `prompt`、`model_id`、`threshold` 等元数据。

`scripts/infer.py` 负责命令行入口。它支持单图、本地文件夹和图片 URL 三种输入方式，并为每张图片保存两类输出：一是带有检测框的可视化图片，二是 JSON 格式的结构化预测结果。该 JSON 后续会被 `eval_coco.py` 读取并转换成 COCO detection result 格式。

当前 repo 中与推理相关的核心调用链如下：

```
scripts/infer.py
-> read_prompt_file()
-> collect_images()
-> GroundingDinoDetector(...)
    -> AutoProcessor.from_pretrained()
    -> AutoModelForZeroShotObjectDetection.from_pretrained()
-> predict_image()
    -> detector.predict()
        -> normalize_prompt()
        -> processor(images, text)
        -> model(**inputs)
        -> post_process_grounded_object_detection()
    -> apply_nms()
```

```

-> apply_score_cutoff()
-> draw_detections()
-> save JSON + visualization

```

3.5 后处理: NMS 与 score cutoff

per-class prompt 会产生更多候选框, 因此我们进一步加入同类别 NMS (Non-Maximum Suppression)。对于同一类别、同一图像中的预测框, 如果 IoU 大于 0.5, 则只保留置信度最高的框。最终改进方法为:

```
per-class prompt + per-label NMS, IoU threshold = 0.5
```

此外, 项目还实现了 post-score cutoff, 用于在 NMS 后进一步过滤低置信度预测。该步骤不改变模型输出本身, 只是在后处理阶段删除低于指定 score 的预测框, 方便进行 precision-recall 取舍分析。在实验中, 我们使用 0.30、0.35 和 0.40 三个 cutoff 观察候选框数量、AP 和 AR 的变化。

3.6 COCO 格式转换与评估接口

为了使用标准 COCOeval 指标, 本项目将 Grounding DINO 的 JSON 输出转换为 COCO detection result 格式。转换过程包括三步: 首先, 根据图片文件名 stem 找到对应的 COCO image_id; 其次, 将预测框从 xyxy 转换为 COCO 所需的 xywh; 最后, 将模型输出的 text_labels 映射到 COCO 20 类的 category_id。

由于 Grounding DINO 输出的是开放文本标签, 模型有时会产生 a person、the dog 或混合短语。因此评估脚本会先将标签小写化, 并去除 a、an、the 等冠词, 再与 COCO 类别名进行精确匹配。无法匹配的预测不会参与 COCOeval, 而是写入 unmatched_predictions.csv, 用于分析开放词汇标签匹配失败问题。

4 Experiments

4.1 Datasets

本项目使用 COCO val2017 作为评估数据来源。为了控制实验规模并贴合开放词汇检测任务, 我们从 COCO val2017 中选取 20 个常见类别:

```

person, bicycle, car, motorcycle, bus, truck, traffic light,
dog, cat, horse, chair, couch, dining table, bottle, cup,
laptop, book, backpack, umbrella, cell phone

```

本文主要实验使用 1000 张图片正式实验子集。该子集包含 1000 张图片、20 个类别和 5892 个标注框。数据准备脚本会保留 COCO annotation 格式, 方便后续使用 COCOeval 进行标准目标检测评估。

4.2 Implementation Details

项目使用 Python 实现, 主要依赖 PyTorch、HuggingFace Transformers、Pillow、pycocotools、matplotlib 和 tqdm。主要脚本包括:

- `scripts/infer.py`: 执行 Grounding DINO 推理并生成可视化图和 JSON 结果;
- `scripts/prepare_coco_subset.py`: 构建 COCO 子集;
- `scripts/eval_coco.py`: 将预测结果转为 COCO detection 格式并计算指标;
- `scripts/export_failure_cases.py`: 导出 false positive 和 false negative 失败案例图。

表 1: 主要实验配置

配置项	设置
模型	IDEA-Research/grounding-dino-base
图像数量	1000
类别数量	20
box threshold	0.25
text threshold	0.25
NMS IoU threshold	0.5
评估工具	COCOeval

4.3 Metrics

本项目采用 COCO 目标检测标准指标:

- AP: IoU 从 0.50 到 0.95, 步长 0.05 的平均精度;
- AP50: IoU = 0.50 时的平均精度;
- AP75: IoU = 0.75 时的平均精度;
- AP_small / AP_medium / AP_large: 不同目标尺寸下的 AP;
- AR100: 每张图最多保留 100 个检测框时的平均召回率。

其中 AP 是最主要的综合指标, AP50 更能反映较宽松定位条件下的检测能力, AR100 反映模型是否能够尽可能召回真实目标。

4.4 Experimental design & results

4.4.1 Threshold 调整

最初使用默认 threshold: box threshold = 0.40, text threshold = 0.30。在 1000 张 grounding-dino-base 正式实验中, 默认 threshold 过于保守, AP 只有 0.0732, AR100 只有 0.0883; 降低到 0.25 / 0.25 后, AP 提升到 0.2073, AP50 提升到 0.2975, AR100 提升到 0.3073。继续降低到 0.20 / 0.20 时, 有效预测数从 5924 增加到 11272, 未匹配预测数从 731 增加到 2188, 误检和标签匹配失败变多, AP 下降到 0.1804。因此后续主实验采用 box threshold = 0.25, text threshold = 0.25。

4.4.2 Multi-class Prompt 与 Per-class Prompt 对比

1000 张 COCO 子集上的主要结果如表 2 所示。

表 2: 1000 张 COCO 子集实验结果

方法	AP	AP50	AP75	AR100	有效预测数	未匹配数
multi-class prompt, 0.40 / 0.30	0.0732	0.0988	0.0820	0.0883	1263	10
multi-class prompt, 0.25 / 0.25	0.2073	0.2975	0.2289	0.3073	5924	731
multi-class prompt, 0.20 / 0.20	0.1804	0.2780	0.1924	0.3023	11272	2188
per-class prompt + NMS	0.1284	0.1592	0.1427	0.4478	29706	0
per-class + NMS + score cutoff 0.30	0.1225	0.1500	0.1364	0.3997	20956	0
per-class + NMS + score cutoff 0.35	0.1174	0.1420	0.1308	0.3578	14872	0
per-class + NMS + score cutoff 0.40	0.1122	0.1348	0.1252	0.3239	10321	0

从结果可以看出, 在 1000 张图片的 grounding-dino-base 实验中, 最佳 AP 来自 multi-class prompt, 0.25 / 0.25。per-class prompt + NMS 并没有提高 AP, 但它有两个明显效果: 第一, 未匹配预测数从 731 降到 0, 说明逐类别 prompt 消除了混合文本标签导致的类别映射失败; 第二, AR100 从 0.3073 提升到 0.4478, 说明它能找回更多真实目标。

代价也很明显: per-class prompt + NMS 的有效预测数达到 29706, 是 multi-class 0.25 / 0.25 的约 5 倍, false positive 明显增加, 因此 precision 和 AP 下降。score cutoff 可以减少预测数量, 但同时也会降低 recall, 最终 AP 仍低于 multi-class 0.25 / 0.25。




图 1: 1000 张 COCO 子集 threshold 对比




图 2: 1000 张 COCO 子集 prompt 和 score cutoff 对比

4.4.3 每类 AP 分析

在最佳配置 multi-class prompt, 0.25 / 0.25 下, 表现较好的类别包括 laptop、person、cat、bus、couch 和 cup; 表现较差的类别包括 book、dog、truck、bicycle、traffic light 和 cell phone。这说明 Grounding DINO 对大目标、外观清晰的类别更加稳定, 而对小目标、遮挡目标和视觉差

异较大的类别仍然困难。

表 3: 最佳配置下 AP 较高的类别

类别	AP
laptop	0.6821
person	0.4329
cat	0.4196
bus	0.4046
couch	0.3252
cup	0.2362

per-class prompt + NMS 对少数低召回类别有帮助, 例如 dog 的 AP 从 0.0347 提升到 0.1910, truck 从 0.0387 提升到 0.1454, bicycle 从 0.0529 提升到 0.0762。但是它也会显著降低一些原本检测较好的类别, 例如 laptop 从 0.6821 降到 0.3055, cat 从 0.4196 降到 0.1866, bus 从 0.4046 降到 0.2071。因此, 本实验最终将 per-class prompt 视为 recall-oriented 改进, 而不是整体 AP 最优方案。




图 3: 最佳配置每类 AP

4.4.4 失败案例分析

我们额外实现了失败案例导出脚本, 对预测结果进行 IoU 匹配, 并可视化 false positive 和 false negative。图中绿色框表示 ground truth, 蓝色框表示 true positive, 红色框表示 false positive, 橙色框表示 false negative。

典型失败现象包括: 小目标漏检, traffic light、book、bottle 等小目标容易被忽略; 密集目标误检, 多人、多物体场景中容易产生重复框; 相似类别混淆, chair 与 couch、bus 与 truck 等类别存在混淆; per-class prompt 提高 recall 后, false positive 数量也增加。



图 4: Multi-class false negative case



图 5: Per-class false positive case

5 Conclusion

本项目复现了基于 Grounding DINO 的开放词汇目标检测流程,并在 COCO val2017 的 1000 张、20 类子集上完成了定量评估和结果分析。实验表明, threshold 对开放词汇检测性能影响明显,过高阈值会导致严重漏检;将 box threshold 和 text threshold 设为 0.25 后, AP 从 0.0732 提升到 0.2073, AR100 从 0.0883 提升到 0.3073。

进一步地,我们实现了 per-class prompt + NMS 的改进方法。该方法通过逐类别查询减少

文本标签混乱问题，将未匹配预测数从 731 降至 0，并将 AR100 从 0.3073 提升到 0.4478。但它同时产生大量候选框，使有效预测数增加到 29706，false positive 增多，AP 下降到 0.1284。因此，本实验最终选择 multi-class prompt, 0.25 / 0.25 作为 AP 最优配置，而将 per-class prompt + NMS 作为提高 recall 和减少标签混乱的补充方案。

未来可以继续探索更好的 prompt 模板、类别自适应阈值、跨类别 NMS、按类别单独调节 score cutoff，以及 YOLO-World 或 GLIP 等其他开放词汇检测模型来进一步提升性能。

Reference

- [1] S. Liu, Z. Zeng, T. Ren, F. Li, H. Zhang, J. Yang, et al. Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection. arXiv:2303.05499, 2023.
- [2] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, et al. Learning Transferable Visual Models From Natural Language Supervision. ICML, 2021.
- [3] M. Minderer, A. Gritsenko, A. Stone, M. Neumann, D. Weissenborn, A. Dosovitskiy, et al. Simple Open-Vocabulary Object Detection with Vision Transformers. ECCV, 2022.
- [4] L. H. Li, P. Zhang, H. Zhang, J. Yang, C. Li, Y. Zhong, et al. Grounded Language-Image Pre-training. CVPR, 2022.
- [5] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick. Microsoft COCO: Common Objects in Context. ECCV, 2014.
- [6] HuggingFace Transformers Documentation. Grounding DINO model documentation. https://huggingface.co/docs/transformers/model_doc/grounding-dino

Contributions

- 崔子璇 (12311007, 25%): 负责第 1 章 Introduction 和第 2 章 Related Works 的汇报与内容整理，包括开放词汇目标检测任务背景、项目动机、传统检测与开放词汇检测的区别，以及 CLIP、OWL-ViT、GLIP、Grounding DINO 等相关工作的对比介绍。
- 李泽均 (12311010, 25%): 负责第 3 章 Approach 的汇报与实现说明，包括 Grounding DINO 模型流程、HuggingFace 模型封装、prompt 设计、推理调用链、NMS / score cutoff 后处理，以及 COCO 格式转换接口。
- 唐明强 (12312417, 25%): 负责第 4.1 至第 4.3 节的汇报与实验准备，包括 COCO 1000 张子集构建、20 类类别选择、实现细节说明、AP / AP50 / AP75 / AR100 等评价指标解释，以及实验配置整理。
- 李程 (12111913, 25%): 负责第 4.4 至第 5 章的汇报与结果分析，包括 threshold 对比、multi-class 与 per-class prompt 对比、每类 AP 分析、false positive / false negative 失败案例分析、结论总结和后续改进方向整理。